

自然语言处理

实验指导

目 录

- 安装Anaconda
- 环境搭建1: conda或pip换源
- 环境搭建2: 安装Pytorch
- 环境搭建3: 安装其余依赖
- 模型训练
- 模型推断
- 实验三环境安装与调试
- 配置IDE
- 华为云环境配置

1.1 安装Anaconda（可选，推荐）

■ 为什么需要虚拟环境

- 可以让每个项目配置一个自定义的Python解释器环境
- 尤其是AI领域中，不同参考实现的环境之间大多存在差异与冲突，更需要使用虚拟环境来管理

■ 为什么选用conda

- conda包含在Anaconda中，是虚拟环境和包管理的集成
- 相比于python自带的virtualenv虚拟环境：conda预安装了numpy等库，方便科学计算；conda集成了包管理器，能够方便地安装CUDA等GPU开发环境下需要的非Python工具

■ 如何安装Anaconda

- 参考<https://zhuanlan.zhihu.com/p/75717350> 推荐清华源下载

1.2 conda或pip换源

- 由于下载使用的默认服务器通常在国外，速度偏慢，一般直接采用国内镜像对下载服务器（源）进行替换。
- conda换源
 - 修改用户目录下的 `.condarc` 文件。Windows 用户无法直接创建名为 `.condarc` 的文件，可先执行 `conda config --set show_channel_urls yes` 生成该文件之后再修改。
 - 以换成清华源为例，修改内容参照：
<https://mirrors.tuna.tsinghua.edu.cn/help/anaconda/>
- pip换源
 - 如果没有使用虚拟环境，则需要使用pip安装依赖，pip换源请参考：
<https://mirrors.tuna.tsinghua.edu.cn/help/pypi/>

1.3 实验一/二：安装Pytorch

■ 使用Anacoda:

在Anaconda Prompt中进行如下操作:

创建虚拟环境并激活

```
conda create -n nlplab python=3.7 # 创建名为  
nlplab 的虚拟环境
```

```
conda activate nlplab # 激活虚拟环境nlplab, 成  
功执行后应看到命令行首部由 (base) 变为  
(nlplab)
```


安装 Pytorch 1.7.1 CPU 版本

```
conda install pytorch=1.7.1
```

其他虚拟环境相关命令


```
conda deactivate # 退出当前虚拟环境
```

```
conda info -e # 查看所有虚拟环境, *指示当前所  
处环境
```



■ 如果使用pip, 直接运行:

- ❑ `pip install torch==1.7.1+cpu torchvision==0.8.2+cpu torchaudio==0.7.2 -f https://download.pytorch.org/whl/torch_stable.html`



A terminal window titled "3. faan@cciiip-2080TI:~/nlplab/Bi-LSTM+CRF (ssh)" displays the execution of a pip command to install PyTorch and its dependencies. The command is: `(base) → Bi-LSTM+CRF pip install torch==1.7.1+cpu torchvision==0.8.2+cpu torchaudio==0.7.2 -f https://download.pytorch.org/whl/torch_stable.html`. The terminal output shows the process of looking in indexes and links, collecting the packages, and downloading them. Progress bars are shown for the torch and torchvision downloads. The torch download is 159.4MB at 407kB/s, and the torchvision download is 11.8MB at 11.6MB/s. The torchaudio download is also shown.

```
3. faan@cciiip-2080TI:~/nlplab/Bi-LSTM+CRF (ssh)
(base) → Bi-LSTM+CRF pip install torch==1.7.1+cpu torchvision==0.8.2+cpu torchaudio==0.7.2 -f https://download.pytorch.org/whl/torch_stable.html

Looking in indexes: https://pypi.tuna.tsinghua.edu.cn/simple
Looking in links: https://download.pytorch.org/whl/torch_stable.html
Collecting torch==1.7.1+cpu
  Downloading https://download.pytorch.org/whl/cpu/torch-1.7.1%2Bcpu-cp37-cp37m-linux_x86_64.whl (159.4MB)
    |████████████████████████████████████████| 159.4MB 407kB/s
Collecting torchvision==0.8.2+cpu
  Downloading https://download.pytorch.org/whl/cpu/torchvision-0.8.2%2Bcpu-cp37-cp37m-linux_x86_64.whl (11.8MB)
    |████████████████████████████████████████| 11.8MB 11.6MB/s
Collecting torchaudio==0.7.2
  Downloading https://pypi.tuna.tsinghua.edu.cn/packages/37/16/ecdb9eb09ec6b8133
```

1.4 安装其余依赖

- 由于本项目所使用的部分依赖项并未被conda收录，只能使用pip安装所有依赖：
 - `pip install -r requirements.txt`
- 如果安装速度过慢请检查是否成功配置了1.2中的pip换源。

1.5 华为云

■ 创建OBS桶，上传实验数据：

- ❑ 登录OBS平台并创建桶
- ❑ 新建“NLP”文件夹
- ❑ 本地解压实验数据，上传至云端“NLP”文件夹

■ 创建notebook开发环境

- ❑ 登录华为云modelarts控制台
- ❑ 点击开发环境->notebook->创建，并输入notebook描述
- ❑ 选择Ascend 910环境
- ❑ notebook存储位置选择之前创建的“NLP”文件夹

MindSpore中Bi-LSTM+CRF链接：https://www.mindspore.cn/tutorials/application/zh-CN/r1.7/nlp/sequence_labeling.html

1.6 模型训练

■ 依次运行数据预处理、模型训练

□ 数据预处理: `cd data && python data_u.py`

```

2. faan@ccitp-2080TI:~/nlp/Bi-LSTM+CRF/data (ssh)
(nlplab) → Bi-LSTM+CRF cd data && python data_u.py
[0, 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 18, 19, 20, 21, 7, 22, 23, 24, 25, 18,
10, 11, 12, 13, 26, 27, 28, 7, 29, 30, 31, 28, 18, 32, 33, 18, 34, 35, 36, 37]
['人', '们', '常', '说', '生', '活', '是', '一', '部', '教', '科', '书', '而', '血', '与',
'火', '的', '战', '争', '更', '是', '不', '可', '多', '得', '的', '教', '科', '书', '她', '确',
'实', '是', '名', '副', '其', '实', '的', '我', '的', '大', '学', '。']
[3, 0, 2, 3, 3, 0, 2, 3, 3, 3, 0, 1, 2, 3, 3, 3, 3, 3, 0, 2, 3, 3, 0, 1, 1, 2, 3, 0, 1, 2, 3, 3, 0
, 2, 3, 0, 1, 1, 2, 3, 3, 3, 3, 0, 2, 3, 3]
['S', 'B', 'E', 'S', 'S', 'B', 'E', 'S', 'S', 'S', 'B', 'M', 'E', 'S', 'S', 'S', 'S', 'S', 'S', 'B',
'E', 'S', 'B', 'M', 'M', 'E', 'S', 'S', 'B', 'M', 'E', 'S', 'S', 'B', 'E', 'S', 'B', 'M', 'M', 'E',
S', 'S', 'S', 'S', 'B', 'E', 'S', 'S']
(nlplab) → data

```

□ 模型训练: 项目根目录下运行 `python run.py` [--cuda 使用此参数 需要系统拥有Nvidia独显, 且Pytorch安装gpu版本]

```

2. python run.py (ssh)
(nlplab) → Bi-LSTM+CRF python run.py
2021-05-31 12:31:08,956 DEBUG word_embeddings.weight: torch.Size([5168, 100]), require_grad=True
2021-05-31 12:31:08,956 DEBUG lstm.weight_ih_l0: torch.Size([400, 100]), require_grad=True
2021-05-31 12:31:08,956 DEBUG lstm.weight_hh_l0: torch.Size([400, 100]), require_grad=True
2021-05-31 12:31:08,957 DEBUG lstm.bias_ih_l0: torch.Size([400]), require_grad=True
2021-05-31 12:31:08,957 DEBUG lstm.bias_hh_l0: torch.Size([400]), require_grad=True
2021-05-31 12:31:08,957 DEBUG lstm.weight_ih_l0_reverse: torch.Size([400, 100]), require_grad=True
2021-05-31 12:31:08,957 DEBUG lstm.weight_hh_l0_reverse: torch.Size([400, 100]), require_grad=True
2021-05-31 12:31:08,957 DEBUG lstm.bias_ih_l0_reverse: torch.Size([400]), require_grad=True
2021-05-31 12:31:08,957 DEBUG lstm.bias_hh_l0_reverse: torch.Size([400]), require_grad=True
2021-05-31 12:31:08,957 DEBUG hidden2tag.weight: torch.Size([4, 200]), require_grad=True
2021-05-31 12:31:08,957 DEBUG hidden2tag.bias: torch.Size([4]), require_grad=True
2021-05-31 12:31:08,957 DEBUG crf.start_transitions: torch.Size([4]), require_grad=True
2021-05-31 12:31:08,957 DEBUG crf.end_transitions: torch.Size([4]), require_grad=True
2021-05-31 12:31:08,957 DEBUG crf.transitions: torch.Size([4, 4]), require_grad=True
2021-05-31 12:35:10,478 DEBUG epoch 0-step 100 loss: 25.685805
2021-05-31 12:38:41,506 DEBUG epoch 0-step 200 loss: 12.174740

```

1.7 模型预测

■ 运行infer.py: `python infer.py`

- 该脚本在第五行指定了用于预测的模型，需要将其替换为你的保存结果；
- 脚本默认使用save目录中的初始模型进行预测，结果保存为文件。

```
2. faan@cciiip-2080Tl:~/nlplab/Bi-LSTM+CRF (ssh)
(nlplab) → Bi-LSTM+CRF python infer.py
(nlplab) → Bi-LSTM+CRF head cws_result.txt
扬帆 远 东 做 与 中 国 合 作 的 先 行
希 腊 的 经 济 结 构 较 特 殊 。
海 运 业 雄 踞 全 球 之 首 ， 按 吨 位 计 占 世 界 总 数 的 1 7 % 。
另 外 旅 游 、 侨 汇 也 是 经 济 收 入 的 重 要 组 成 部 分 ， 制 造 业 规 模 相 对 较 小 。
多 年 来 ， 中 希 贸 易 始 终 处 于 较 低 的 水 平 ， 希 腊 几 乎 没 有 在 中 国 投 资 。
十 几 年 来 ， 改 革 开 放 的 中 国 经 济 高 速 发 展 ， 远 东 在 崛 起 。
瓦 西 里 斯 的 船 只 中 有 4 0 % 驶 向 远 东 ， 每 个 月 几 乎 都 有 两 三 条 船 停 靠
中 国 港 口 。
他 感 受 到 了 中 国 经 济 发 展 的 大 潮 。
他 要 与 中 国 人 合 作 。
他 来 到 中 国 ， 成 为 第 一 个 访 华 的 大 船 主 。
```

1.8 实验三环境及测试

- 推荐新建一个conda环境，使用较新的pytorch版本。

```
conda create -n lfs python=3.10
conda activate lfs
pip install torch --index-url https://download.pytorch.org/whl/cpu
# if gpu delete url
pip install ipykernel
```

- 进入llm-from-scratch.ipynb，在其中按顺序执行每个 Cell，填写标注了 [学生填空点] 的代码块，并通过末尾的验证函数确认实现正确。

- （可选）额外实验：KV Cache 压缩。

```
cd llm-experiments/kv_cache_arena
pip install -r requirements.txt
```

修改完strategy.py后使用python run_eval.py进行效果评估。


2.1 配置IDE

- 在需要对于已有代码进行修改时，IDE能够方便你进行调试等操作。推荐使用的IDE有：功能最为完备的PyCharm、或者更轻量的VsCode。
 - **PyCharm**：功能更加完备，如图形化管理环境依赖、远程项目修改时可增量修改。
 - **VsCode**：轻量，拓展性强，通过插件支持各类语言。因为需要安装插件，所以不是开箱即用的。

2.1 配置IDE

■ PyCharm开发环境配置


- 点击 File/Settings 打开设置页，搜索 Project Interpreter 选择配置好的 nlplab 环境即可



2.1 配置IDE

■ VsCode开发环境配置


- 在插件页安装Python解释器插件：




2.1 配置IDE

■ VsCode开发环境配置

- 在Vscode中打开任意Python文件，点击左下角选择环境：



- 在弹出窗口中选择创建完成的nlplab虚拟环境：



- 单击键盘F5按键，选择调试方式即可。

2.2 课外拓展

- 了解信息抽取前沿论文，在 ModelArts 平台上尝试复现

参考文献

- Boundary Smoothing for Named Entity Recognition
- Label Semantics for Few Shot Named Entity Recognition
- A Simple yet Effective Relation Information Guided Approach for Few-Shot Relation Extraction
- Event-Event Relation Extraction using Probabilistic Box Embedding

- 华为云CSIG2022:中英文购物小票信息理解大赛

华为云大赛 > 大赛列表 > 大赛详情

CSIG2022:中英文购物小票信息理解大赛

火热进行中

该任务旨在探索算法对复杂视觉信息理解的能力。参赛队伍需要设计算法，结合人工标注的OCR文字框，以及文字，对图像中的关键信息进行理解，重点考察参赛选手对关键信息的抽取，筛选，整理和汇聚的能力。

举办方：中国图象图形学学会、华为竞赛部、华为质量与流程IT、华为云大赛平台、华为云ModelArts

奖金：¥100,000

67
团队数

326
报名人数

初赛截止时间：2022/07/18