关卡 4
基于 Hive 的数据处理

华为技术有限公司

目录

1 实验环境介绍 2
1.1 实验介绍 2
1.1.1 关于本实验 2
1.1.2 实验目的 2
2 基于 Hive 的数据处理 3
2.1 实验任务 3
2.1.1 上传模拟数据 3
2.1.2 连接 Hive 环境 4
2.1.3 问题一 4
2.1.4 问题二 5
2.1.5 问题三 6
2.1.6 问题四 7
2.1.7 部署 Kunpeng Hyper Tuner 8
2.1.8 使用 Kunpeng Hyper Tuner 优化 9
2.2 思考题 16

1 实验环境介绍

1.1 实验介绍

1.1.1 关于本实验

本实验主要介绍在 Hadoop 的帮助下存储大量数据时，使用 Hive 的 HQL 语句简化 MapReduce 任务的实现，根据要求完成数据分析的任务。同时部署 Kunpeng Hyper Tuner 定位相关性能问题并使用优化手段缩短任务运行的时间。

1.1.2 实验目的

帮助学员了解基础大数据环境，完成简单数据分析任务，并部署 Kunpeng Hyper Tuner 分析性能问题，使用优化手段缩短任务运行时间。

2 基于 Hive 的数据处理

2.1 实验任务

2.1.1 上传模拟数据

步骤 1 模拟数据地址

/ src / main / resources / **others** /

数据文件为在后端代码工程文件 others 目录下的 conversation.txt 和 message.txt。

```
cd ~
mkdir testData
cd /home/IMSystem/src/main/resources/others
cp conversation.txt /root/testData/conversation.txt
cp messages.txt /root/testData/messages.txt
cd /root/testData
ll
```

```
[root@server1 testData]# ll
total 8.6M
-rw------- 1 root root 445K Jan 20 17:49 conversation.txt
-rw------- 1 root root 8.1M Jan 20 17:49 messages.txt
```

步骤 2 将模拟数据上传 hdfs

```
hdfs dfs -ls /
hdfs dfs -mkdir /user/Hadoop
hdfs dfs -put /root/testData /user/Hadoop
hdfs dfs -ls /user/Hadoop/testData
```

```
[root@server1 testData]# hdfs dfs -ls /user/Hadoop/testData
Found 2 items
-rw-r--r--   1 root supergroup     455450 2022-01-22 14:57 /user/Hadoop/testData/conversation.txt
-rw-r--r--   1 root supergroup    8456388 2022-01-22 14:57 /user/Hadoop/testData/messages.txt
```

步骤 3 修改文件权限

```
hdfs dfs -chmod -R 777 /user
hdfs dfs -chmod -R 777 /tmp
```

2.1.2 连接 Hive 环境

步骤 1 运行 hive 及 hadoop

如果 hive 和 hadoop 关闭，可根据关卡一的操作启动 hive 和 hadoop。

步骤 2 使用 beeline 连接 Hive

```
beeline -u jdbc:hive2://server1:10000
```

```
[root@server1 testData]# beeline -u jdbc:hive2://server1:10000
SLF4J: Class path contains multiple SLF4J bindings.
SLF4J: Found binding in [jar:file:/usr/local/apache-hive-3.1.2-bin/lib/log4j-slf4j-impl-2.10.0.jar!/org/slf4j/impl/StaticLoggerBinder.class]
SLF4J: Found binding in [jar:file:/usr/local/hadoop-3.3.1/share/hadoop/common/lib/slf4j-log4j12-1.7.30.jar!/org/slf4j/impl/StaticLoggerBinder.class]
SLF4J: See http://www.slf4j.org/codes.html#multiple_bindings for an explanation.
SLF4J: Actual binding is of type [org.apache.logging.slf4j.Log4jLoggerFactory]
Connecting to jdbc:hive2://server1:10000
Connected to: Apache Hive (version 3.1.2)
Driver: Hive JDBC (version 3.1.2)
Transaction isolation: TRANSACTION_REPEATABLE_READ
Beeline version 3.1.2 by Apache Hive
0: jdbc:hive2://server1:10000>
```

2.1.3 问题一

假设 00:00:00-00:59:59 为一个小时，请问每个用户的聊天记录在这 24 个时间段内出现的次数分别为多少?

步骤 1 新建 hive 表

```
CREATE TABLE chatfrequency(`id` string, `conversation_id` string, `sender_id` string, `msg_type` string, `msg_content` string, `chat_time` string)
ROW FORMAT delimited
FIELDS TERMINATED BY ';'
LINES TERMINATED BY '\n';
```

步骤 2 验证表 chatfrequency 是否创建完成

```
desc chatfrequency;
```

col_name	data_type	comment
id	string	
conversation_id	string	
sender_id	string	
msg_type	string	
msg_content	string	
chat_time	string	

步骤 3 从 hdfs 加载数据到 hive 表

```
LOAD DATA INPATH 'hdfs://server1:9000/user/Hadoop/testData/messages.txt' OVERWRITE INTO TABLE chatfrequency;
```

步骤 4 验证数据是否导入成功

```
select count(1) from chatfrequency;
```

```
INFO  : OK
INFO  : Concurrency mode is disabled, not creating a lock manager
+---------+
|   _c0   |
+---------+
| 100000  |
+---------+
```

2.1.3.2 参考答案

```
SELECT sender_id,hour(regexp_replace(chat_time, '/', '-')),count(1) AS count
FROM chatfrequency c
GROUP BY hour(regexp_replace(chat_time, '/', '-')),c.sender_id
ORDER BY c.sender_id,count desc;
```

```
+------------+------+--------+
| sender_id  | _c1  | count  |
+------------+------+--------+
| 1          | 15   | 2155   |
| 1          | 19   | 2138   |
| 1          | 11   | 2134   |
| 1          | 17   | 2133   |
| 1          | 7    | 2124   |
| 1          | 1    | 2120   |
| 1          | 12   | 2119   |
| 1          | 10   | 2116   |
| 1          | 8    | 2115   |
| 1          | 9    | 2112   |
| 1          | 13   | 2110   |
| 1          | 14   | 2109   |
| 1          | 2    | 2108   |
| 1          | 18   | 2095   |
| 1          | 3    | 2089   |
| 1          | 21   | 2088   |
| 1          | 20   | 2078   |
| 1          | 5    | 2077   |
| 1          | 22   | 2074   |
| 1          | 4    | 2060   |
| 1          | 16   | 2052   |
| 1          | 6    | 2051   |
| 1          | 23   | 2047   |
| 1          | 0    | 2037   |
| 2          | 13   | 2173   |
| 2          | 1    | 2153   |
| 2          | 8    | 2149   |
| 2          | 11   | 2146   |
| 2          | 17   | 2129   |
| 2          | 9    | 2123   |
| 2          | 7    | 2104   |
| 2          | 10   | 2092   |
| 2          | 12   | 2091   |
| 2          | 14   | 2066   |
| 2          | 4    | 2056   |
| 2          | 6    | 2054   |
| 2          | 22   | 2053   |
| 2          | 21   | 2050   |
| 2          | 3    | 2048   |
| 2          | 2    | 2041   |
| 2          | 19   | 2038   |
| 2          | 23   | 2022   |
| 2          | 0    | 2020   |
| 2          | 20   | 2018   |
| 2          | 18   | 2015   |
| 2          | 16   | 2012   |
| 2          | 15   | 2004   |
| 2          | 5    | 2002   |
+------------+------+--------+
48 rows selected (40.198 seconds)
0: jdbc:hive2://server1:10000>
```

2.1.4 问题二

第一小题：在所有的聊天内容中，每个汉字各自出现了多少次？将结果按照递减的方法进行排序（message.txt）。

2.1.4.1 参考答案

```
SELECT word,count(1) AS count
FROM (SELECT explode(split(regexp_replace(msg_content,'\u3002',''),'(?!\\A|\\z)')) AS word FROM
chatfrequency) w
```

```
GROUP BY word
ORDER BY count DESC;
```

```
INFO  : Concurrency mode is
+-------+--------+
| word  | count  |
+-------+--------+
| 电    | 3165   |
| 运    | 3163   |
| 列    | 3137   |
| 放    | 3137   |
| 近    | 3135   |
| 产    | 3127   |
| 术    | 3126   |
| 小    | 3125   |
| 济    | 3118   |
| 起    | 3111   |
| 设    | 3111   |
| 件    | 3110   |
| 将    | 3109   |
| 间    | 3109   |
| 每    | 3108   |
| 题    | 3105   |
| 状    | 3105   |
| 已    | 3104   |
| 消    | 3103   |
| 高    | 3101   |
| 参    | 3100   |
| 江    | 3098   |
| 识    | 3096   |
| 平    | 3096   |
| 声    | 3096   |
| 亲    | 3095   |
| 以    | 3093   |
| 称    | 3093   |
| 车    | 3091   |
| 代    | 3086   |
| 完    | 3086   |
| 金    | 3084   |
| 做    | 3083   |
| 织    | 3082   |
| 义    | 3082   |
| 业    | 3081   |
| 深    | 3081   |
| 持    | 3079   |
```

2.1.5 问题三

在所有的对话标题中，每个汉字各自出现了多少次？将结果按照递减的方法进行排序（conversation.txt）。

步骤 1　新建 hive 表

```
CREATE TABLE conversation(`id` string, `title` string, `creator_id` string, `create_time` string)
ROW FORMAT DELIMITED
FIELDS TERMINATED BY ';'
LINES TERMINATED BY '\n';
```

步骤 2　验证表 conversation 是否创建完成

```
desc conversation;
```

```
+--------------+------------+----------+
|   col_name   | data_type  | comment  |
+--------------+------------+----------+
| id           | string     |          |
| title        | string     |          |
| creator_id   | string     |          |
| create_time  | string     |          |
+--------------+------------+----------+
```

步骤 3　加载数据

```
LOAD DATA INPATH 'hdfs://server1:9000/user/Hadoop/testData/conversation.txt' OVERWRITE INTO TABLE conversation;
```

步骤 4　验证数据是否导入成功

```
select count(1) from conversation;
```

```
INFO  : OK
INFO  : Concurrency mode is disabled, not creating a lock manager
+--------+
|  _c0   |
+--------+
| 10000  |
+--------+
```

2.1.5.2 参考答案

```
SELECT title,count(1) AS tcount
FROM (SELECT explode(split(regexp_replace(title,'\u3002',''),'(?!\\A|\\z)')) AS title FROM conversation) c
GROUP BY title
ORDER BY tcount DESC;
```

2.1.6 问题四

在聊天内容中出现频率较高的汉字在对话标题中各自出现了多少次？将结果以聊天内容中出现频率递减的方式排序。

2.1.6.1 参考答案

```
SELECT * FROM
(SELECT word,count(1) AS wcount
FROM (SELECT explode(split(regexp_replace(msg_content,'\u3002',''),'(?!\\A|\\z)')) AS word FROM chatfrequency) w
GROUP BY word) w
JOIN
(SELECT title,count(1) AS tcount
FROM (SELECT explode(split(regexp_replace(title,'\u3002',''),'(?!\\A|\\z)')) AS title FROM conversation) c
GROUP BY title) t
ON (w.word=t.title)
ORDER BY w.wcount DESC;
```

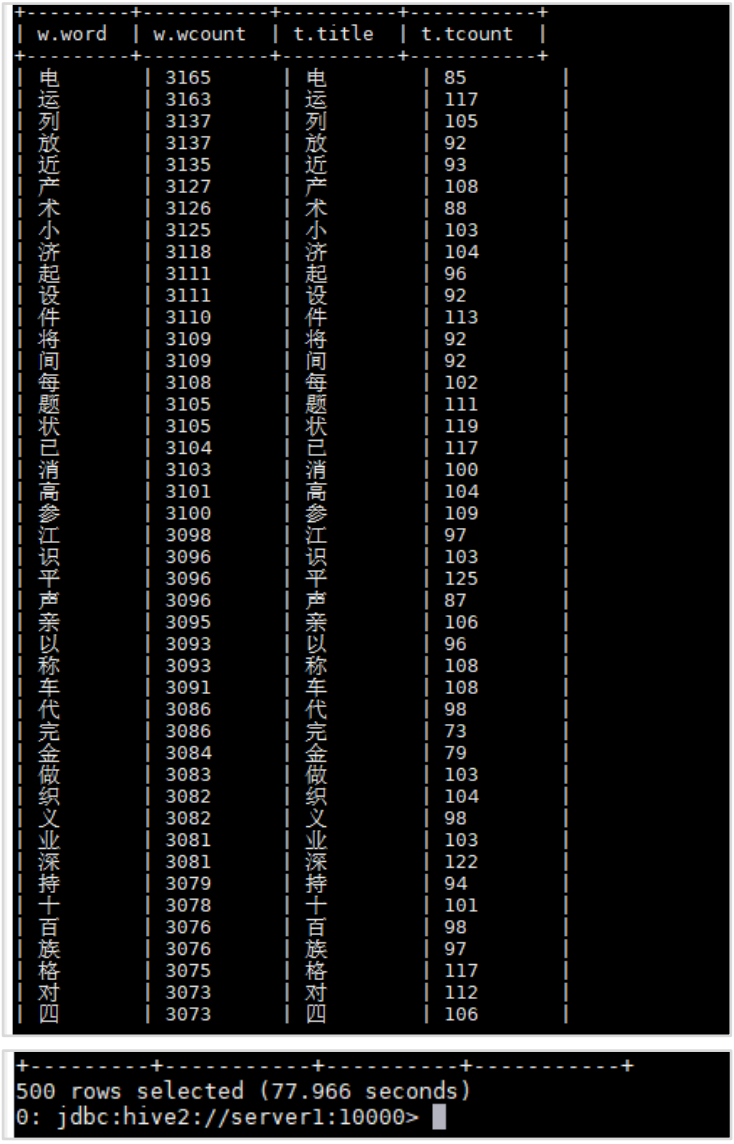

w.word	w.wcount	t.title	t.tcount
电	3165	电	85
运	3163	运	117
列	3137	列	105
放	3137	放	92
近	3135	近	93
产	3127	产	108
术	3126	术	88
小	3125	小	103
济	3118	济	104
起	3111	起	96
设	3111	设	92
件	3110	件	113
将	3109	将	92
间	3109	间	92
每	3108	每	102
题	3105	题	111
状	3105	状	119
已	3104	已	117
消	3103	消	100
高	3101	高	104
参	3100	参	109
江	3098	江	97
识	3096	识	103
平	3096	平	125
声	3096	声	87
亲	3095	亲	106
以	3093	以	96
称	3093	称	108
车	3091	车	108
代	3086	代	98
完	3086	完	73
金	3084	金	79
做	3083	做	103
织	3082	织	104
义	3082	义	98
业	3081	业	103
深	3081	深	122
持	3079	持	94
十	3078	十	101
百	3076	百	98
族	3076	族	97
格	3075	格	117
对	3073	对	112
四	3073	四	106

```
500 rows selected (77.966 seconds)
0: jdbc:hive2://server1:10000>
```

2.1.7 部署 Kunpeng Hyper Tuner

步骤 1　下载 Hyper Tuner

```
cd /home
wget https://mirror.iscas.ac.cn/kunpeng/archive/Tuning_kit/Packages/Hyper-tuner_2.3.T20_linux.tar.gz
```

步骤 2　解压

```
tar -zxvf    Hyper-tuner_2.3.T20_linux.tar.gz
```

步骤 3　临时关闭 SELinux

```
setenforce 0
```

步骤 4　安装

注意：需要自己填写！有两个命令需要填写！

此时仅安装系统性能分析和系统诊断，故初始选项输入 2，后续步骤的设置默认即可。

```
Start installing, please wait!

Hyper_tuner Config Generate
  install tool:
  [1] : System Profiler, System Diagnosis, Tuning Assistant and Java Profiler will be installed
  [2] : System Profiler, System Diagnosis, Tuning Assistant will be installed
  [3] : Java Profiler will be installed
  Please enter a number as install tool. (The default install tool is all):2
```

安装完成。

```
  Start hyper-tuner service success

Hyper_tuner install Success
  ================================================================================
  The login URL of Hyper_Tuner is https://192.168.0.70:8086/user-management/#/login
  ================================================================================
  If 192.168.0.70:8086 has mapping IP, please use the mapping IP.
```

如有问题，可以参考

https://support.huaweicloud.com/hypertuner-install/kunpenginstall_06_0001.html。

步骤 5　使用

在浏览器输入 https://IP:8086/user-management/#/login ，首次登陆需要设置密码。

2.1.8 使用 Kunpeng Hyper Tuner 优化

可以参考大数据场景 Spark 组件的调优实践

https://support.huaweicloud.com/bestpractice-tk-kunpengdevps/kunpengbestspark2_21_0001.html。

步骤 1　选择系统性能分析

步骤 2　创建工程

按照以下内容配置参数。

步骤 3　创建任务

按照下图中信息配置数据。

步骤 4　性能分析

执行任务完成后，出现分析结果页面，以下为各模块截图。

总览提供优化建议以及各项核心硬件的指标数据。

PCIe 拓扑信息页面提供 NUMA 拓扑图、绑核信息以及中断信息。

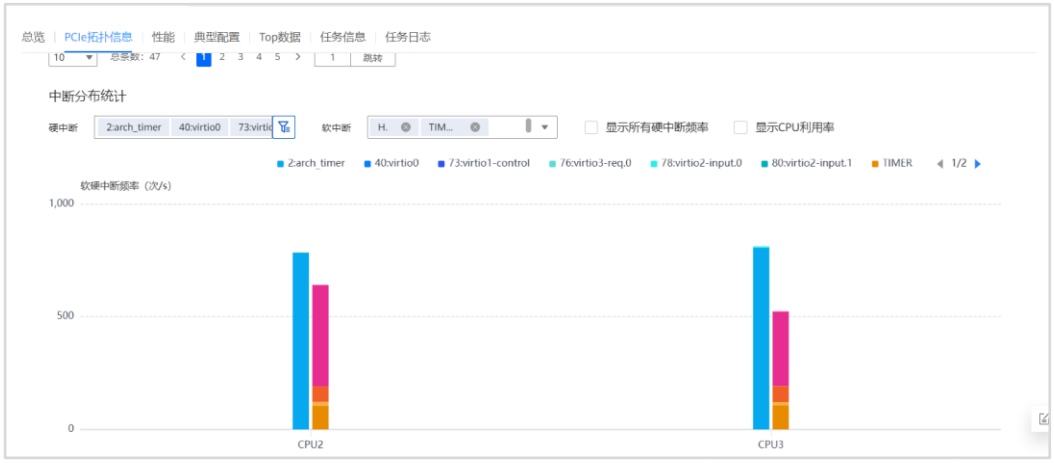

性能模块展示 CPU、内存、网络等使用信息图表。

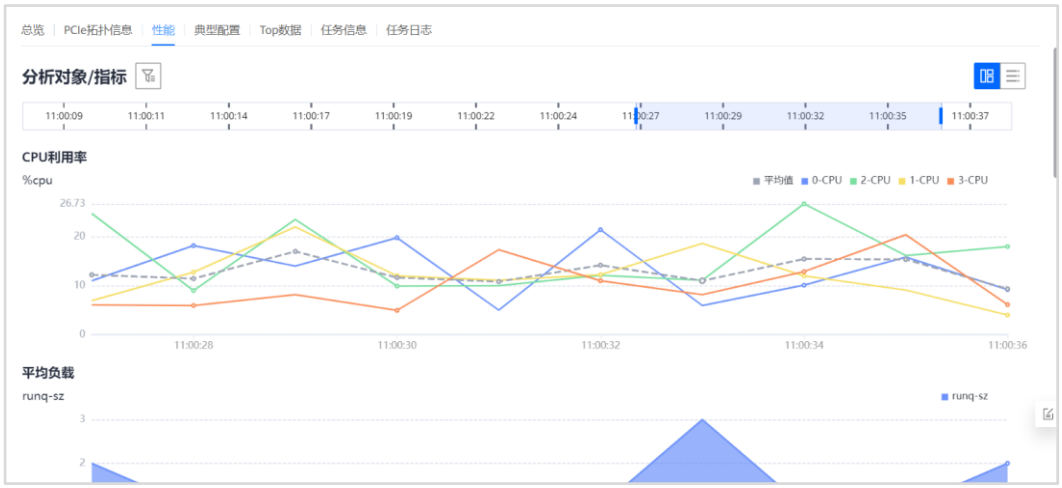

典型配置根据应用场景，提供配置优化建议。

Top 数据定时采集 TOP 数据内容。

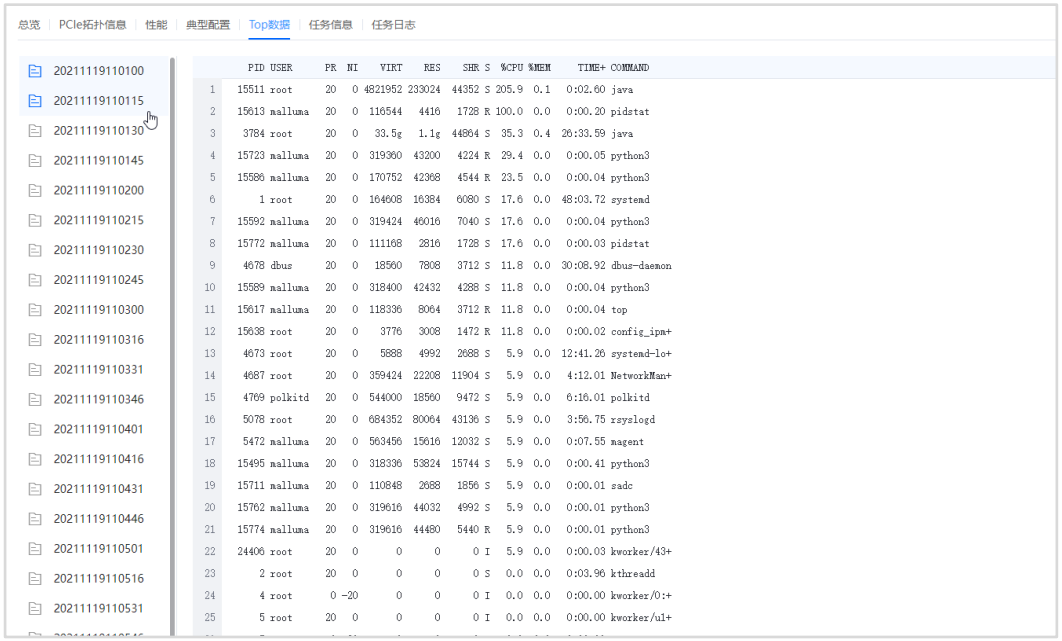

步骤 5 （补充）典型配置调优

由于典型配置功能模块暂不支持云虚拟机，Hive 相关调优项。

通过 set hive.exec.parallel=true;

或修改/usr/local/hive/conf/hive-site.xml 文件中的 hive.exec.parallel 值，

将任务改为并行执行，提高处理任务的效率，缩短处理任务的时间。

步骤 6 优化结果

以问题四为例：

w.word	w.wcount	t.title	t.tcount
电	3165	电	85
运	3163	运	117
列	3137	列	105
放	3137	放	92
近	3135	近	93
产	3127	产	108
术	3126	术	88
小	3125	小	103
济	3118	济	104
起	3111	起	96
设	3111	设	92
件	3110	件	113
将	3109	将	92
间	3109	间	92
每	3108	每	102
题	3105	题	111
状	3105	状	119
已	3104	已	117
消	3103	消	100
高	3101	高	104
参	3100	参	109
江	3098	江	97
识	3096	识	103
平	3096	平	125
声	3096	声	87
亲	3095	亲	106
以	3093	以	96
称	3093	称	108
车	3091	车	108
代	3086	代	98
完	3086	完	73
金	3084	金	79
做	3083	做	103
织	3082	织	104
义	3082	义	98
业	3081	业	103
深	3081	深	122
持	3079	持	94
十	3078	十	101
百	3076	百	98
族	3076	族	97

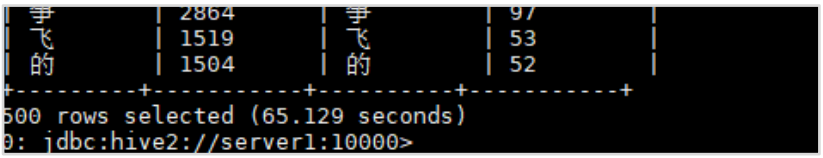

2.2 思考题

在实验中设置了 Hive 的 job 为并发执行，那么在并发执行时，资源消耗和原先的顺序执行是否有所不同?

参考答案：

可在执行问题四中的 HiveQL 语句时，新开命令行窗口，使用 top 命令观察资源使用情况。通过观察可得，资源消耗比顺序执行时更多。